

UNIVERSIDAD NACIONAL DEL SANTA

FACULTAD DE INGENIERÍA

ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS E INFORMÁTICA



ALGORITMOS EVOLUTIVOS Y DE APRENDIZAJE

PRACTICA 08

DOCENTE

- ING. LOPEZ HEREDIA JOHAN MAX ALEXANDER

ESTUDIANTE:

- ROJAS JIMENEZ, DAVID EMANUEL

NUEVO CHIMBOTE – PERÚ

Junio del 2025

Actividad 1: Análisis Comparativo

De las tres representaciones analizadas (binaria, permutacional y real), todas lograron una distribución equilibrada de alumnos entre los tres exámenes, ya que los promedios por grupo fueron muy parecidos y la desviación estándar entre ellos fue la misma (0.0363). Sin embargo, la representación binaria fue la que alcanzó ese equilibrio más rápido, mejorando su resultado en solo 20 generaciones. En cambio, la representación permutacional tardó más en mejorar (40 generaciones), y la representación real no mostró mejoras a lo largo del tiempo. Por lo tanto, la binaria es la más eficiente en cuanto a velocidad de convergencia y equilibrio alcanzado.

Actividad 2: Modificación de Fitness

Al comparar la versión original y la versión modificada del algoritmo con representación binaria, se observa que ambas lograron una distribución equilibrada de los 39 alumnos en tres exámenes (A, B y C), con 13 alumnos por grupo y promedios muy similares: 15.46 para el examen A y 15.38 para los exámenes B y C, resultando en una baja desviación estándar de 0.0363. Sin embargo, la versión modificada utilizó una función de evaluación más exigente, que penaliza la varianza alta dentro de los grupos y premia la diversidad de rendimientos, lo cual provocó que sus valores de fitness fueran más bajos (-0.5911 frente a -0.0363), pero reflejando una distribución más justa y pedagógicamente balanceada.

Actividad 3: Nuevo Operador Genético


Al analizar los resultados con distintos valores de sigma (σ), que controla qué tanto cambian los valores durante la mutación, se observa lo siguiente: con $\sigma = 0.01$, las varianzas fueron A: 11.78, B: 13.33, C: 6.54, mostrando poca variación en los genes y menos equilibrio; con $\sigma = 0.05$, las varianzas fueron A: 11.31, B: 13.17, C: 7.16, un poco mejor, pero aún con diferencia entre los exámenes; con $\sigma = 0.1$, las varianzas fueron A: 10.39, B: 10.09, C: 11.16, es decir, más cercanas entre sí, lo cual indica una mejor distribución; con $\sigma = 0.2$, las varianzas fueron A: 7.62, B: 10.85, C: 13.17, mostrando más desbalance. En todos los casos, los promedios de notas fueron muy similares (entre 15.38 y 15.46) y la diferencia máxima entre ellos fue de solo 0.08. Por eso, el valor $\sigma = 0.1$ parece ser el mejor, ya que logra una buena combinación entre exploración y equilibrio, generando grupos más parejos.

Actividad 4: Restricciones Adicionales

Se utilizó un algoritmo genético para asignar 39 alumnos a tres exámenes (A, B y C), buscando que los promedios sean parecidos. En la versión original, el fitness mejoró de 0.1187 a 0.2637 (122.2% de mejora), mientras que en la versión modificada, que agregó la restricción de no agrupar a todos los alumnos con nota menor a 11 en un solo examen, el fitness subió de 0.2041 a 0.2637 (29.2% de mejora). En ambos casos, los promedios por grupo fueron similares (alrededor de 15.4), la desviación estándar entre promedios fue baja (0.0363) y

los rangos de notas fueron equilibrados (hasta 11 puntos de diferencia), lo que indica una distribución justa y eficaz a pesar de la nueva restricción.

Actividad 5: Visualización (Avanzado)



Actividad 6: Problema Extendido

Para distribuir a 39 alumnos en 4 exámenes en lugar de 3, se modificó el cromosoma aumentando de 3 a 4 bits por alumno, lo que incrementó su tamaño de 117 a 156 bits. Esto permitió asignar a cada alumno uno de los 4 exámenes (A, B, C o D). El cambio facilitó la convergencia del algoritmo genético, ya que con 4 exámenes se logró una distribución casi equilibrada (9-9-9-12 alumnos por examen) y una desviación estándar baja entre promedios (0.0455). En cambio, con 3 exámenes no se encontró una solución válida, manteniéndose el fitness en -1000 durante todas las generaciones, debido a la dificultad de dividir exactamente 39 alumnos en tres grupos iguales de 13.

Preguntas de Reflexión

1. ¿Por qué la representación binaria tuvo dificultades para lograr exactamente 13 alumnos por grupo?

Porque en la representación binaria, cada alumno se asigna a un grupo usando bits (por ejemplo, "00" para A, "01" para B, "10" para C). Sin embargo, no hay una restricción natural que obligue a que cada grupo tenga exactamente 13 alumnos. El algoritmo puede terminar asignando más alumnos a un grupo y menos a otro, lo que causa desequilibrio.

2. ¿Qué ventajas tiene usar valores reales normalizados vs. selección directa?

Los valores reales normalizados (por ejemplo, números entre 0 y 1) permiten más precisión y flexibilidad para ajustar las soluciones. Se pueden transformar fácilmente en asignaciones usando reglas, y facilitan aplicar operadores genéticos como cruce y mutación. En cambio, la selección directa (como elegir grupo A, B o C directamente) es más rígida y puede limitar la exploración del espacio de soluciones.

3. ¿En qué casos la representación permutacional sería inadecuada?

- El problema no se basa en ordenar o distribuir elementos únicos.
- Se permiten repeticiones (porque la permutación asume que todos los elementos son diferentes y únicos).
- Hay muchas restricciones difíciles de cumplir solo reordenando los elementos, como restricciones cruzadas entre alumnos o límites por nota, curso, etc.

4. ¿Cómo afecta el tamaño de la población y número de generaciones a la calidad de la solución?

Una población más grande permite explorar más posibles soluciones, y más generaciones dan más oportunidades para mejorar. Sin embargo, también aumenta el tiempo de cómputo. Si la población es muy pequeña o hay pocas generaciones, el algoritmo puede quedarse atascado en soluciones malas (convergencia prematura).